

HW6

1.

$\Phi_{ds}(x)^T \Phi_{ds}(x')$ 這個東西展開就是 $\sum_{i=1}^d \sum_{\theta=L+0.5}^{R-0.5} \text{sign}(x_i - \theta) \text{sign}(x'_i - \theta)$ ，觀察可以發現當 $\text{sign}(x_i - \theta)$ 跟 $\text{sign}(x'_i - \theta)$ 同號時 $\text{sign}(x_i - \theta) \text{sign}(x'_i - \theta)$ 是正的，其他時是負的。只有當 θ 在 x_i 跟 x'_i 之間時 $\text{sign}(x_i - \theta)$ 跟 $\text{sign}(x'_i - \theta)$ 會不同號，而且因為 s 有 2 種，所以對於每個 i 而言， $\text{sign}(x_i - \theta)$ 跟 $\text{sign}(x'_i - \theta)$ 不同號會發生 $2\|x_i - x'_i\|$ 次。所以對於 x 跟 x' 而言，如果 $\text{sign}(x_i - \theta)$ 跟 $\text{sign}(x'_i - \theta)$ 全部都是同號，因為 s 有 2 種， R 跟 L 之間有 $R-L$ 個 θ ，有 d 種 i ，所以 $\sum_{i=1}^d \sum_{\theta=L+0.5}^{R-0.5} \text{sign}(x_i - \theta) \text{sign}(x'_i - \theta) = 2d(R-L)$ 。但現在其中有 $2\|x_i - x'_i\|$ 是異號的，所以 $\Phi_{ds}(x)^T \Phi_{ds}(x') = 2d(R-L) - 2\|x_i - x'_i\| - 2\|x_i - x'_i\| = 2d(R-L) - 4\|x_i - x'_i\|$ 。

2.

對於所有 α_n ，定 $A_n = \frac{\alpha_n}{u}$ 。顯然當 C 變成 C/u 時， A_n 是符合 0 到 C/u 之間的限制的。原本的 dual problem 要 min 的公式是

$$\begin{aligned} & \frac{1}{2} \sum_{n=1}^N \sum_{m=1}^N \alpha_n \alpha_m y_n y_m K(x_n, x_m) - \sum_{n=1}^N \alpha_n \quad \text{當 } K=uK+v \text{ 時，公式變成} \\ & \frac{1}{2} \sum_{n=1}^N \sum_{m=1}^N \alpha_n \alpha_m y_n y_m (uK(x_n, x_m) + v) - \sum_{n=1}^N \alpha_n = \\ & \frac{u}{2} \sum_{n=1}^N \sum_{m=1}^N A_n A_m y_n y_m K(x_n, x_m) - u \sum_{n=1}^N A_n + \\ & v(\sum_{n=1}^N \sum_{m=1}^N A_n A_m y_n y_m) = \frac{u}{2} \sum_{n=1}^N \sum_{m=1}^N A_n A_m y_n y_m K(x_n, x_m) - \end{aligned}$$

$u \sum_{n=1}^N A_n + v(\sum_{n=1}^N A_n y_n)(\sum_{m=1}^N A_m y_m)$ ，因為 dual problem 有個 constraint 是 $\sum_{n=1}^N A_n y_n = 0$ ，所以

$$\frac{u}{2} \sum_{n=1}^N \sum_{m=1}^N A_n A_m y_n y_m K(x_n, x_m) - u \sum_{n=1}^N A_n +$$

$$v(\sum_{n=1}^N A_n y_n)(\sum_{m=1}^N A_m y_m) = \frac{u}{2} \sum_{n=1}^N \sum_{m=1}^N A_n A_m y_n y_m K(x_n, x_m) -$$

$u \sum_{n=1}^N A_n$ ，也就是原本公式乘上 u 倍。因此解完 QP 後得到的 A 就

是原本 α 解的 $1/u$ 倍。而最終 gsvm 的公式是 $g_{svm}(x) =$

$sign(\sum_{sv} \alpha_n y_n K(x_n, x) + b)$ ，當 $K=uK+v$ ，變成

$$sign(\sum_{sv} A_n y_n (uK(x_n, x) + v) + b) = sign(\sum_{sv} \alpha_n y_n K(x_n, x) + b + v \sum_{sv} \alpha_n y_n) = sign(\sum_{sv} \alpha_n y_n K(x_n, x) + b)$$

，因為 $\sum_{n=1}^N \alpha_n y_n = 0$ 這個 constraint。所以解還是跟原本一樣。

3

講義裡有個公式 $avg(E_{out}(g_t)) = avg(\varepsilon(g_t - G)^2) + E_{out}(G)$ ，所

$$以 1 \geq \frac{E_{out}(G)}{avg(E_{out}(g_t))} = \frac{E_{out}(G)}{\frac{E}{17}} \rightarrow \frac{E_{out}(G)}{E} \leq \frac{1}{17}$$

4

每次拿到特定 data 的機率是 $1-1/N$ ，做 $3/4*N$ 次，所以當 N 趨

$$近無限大時， $\left(1 - \frac{1}{N}\right)^{\frac{3}{4}N} = \left(\frac{N-1}{N}\right)^{\frac{3}{4}N} = \frac{1}{\left(\frac{N}{N-1}\right)^{\frac{3}{4}N}} = \frac{1}{\left(1 + \frac{1}{N-1}\right)^{\frac{3}{4}N}} = \frac{1}{e^{\frac{3}{4}}}。$$$

5

Adaboost 的算法可以確保不管前面正確率多高，只要對 u 做出更新，當下這輪的 u 一定保證 $\frac{\sum_{n:y_n>0} u_n}{\sum_{n:y_n<0} u_n} = 1$ 。所以答案是 1。

6

$U_1 = 1$ ，對於 U_t 而言， ε_t 代表有 $\varepsilon_t U_t$ 這麼多的 u 是屬於 incorrect，需要乘上 $\sqrt{\frac{1-\varepsilon_t}{\varepsilon_t}}$ 。其他部分是除以 $\sqrt{\frac{1-\varepsilon_t}{\varepsilon_t}}$ ，，所以 $U_{t+1} = \varepsilon_t U_t * \sqrt{\frac{1-\varepsilon_t}{\varepsilon_t}} + (1 - \varepsilon_t) U_t * \sqrt{\frac{\varepsilon_t}{1-\varepsilon_t}} = 2\sqrt{\varepsilon_t(1 - \varepsilon_t)} U_t$ ，所以 $\frac{U_{t+1}}{U_t} = 2\sqrt{\varepsilon_t(1 - \varepsilon_t)}$ 。因此 $\frac{U_{T+1}}{U_1} = 2^T \prod_{t=1}^T \sqrt{\varepsilon_t(1 - \varepsilon_t)}$

7.

因為 α_t 就是 minimize $\sum_{n=1}^N ((y_n - s_n) - \eta g_t(x_n))^2$ 的解，所以 $\sum_{n=1}^N ((y_n - s_n) - \eta g_t(x_n))^2$ 對 η 的微分=0。而 $\sum_{n=1}^N ((y_n - s_n) - \eta g_t(x_n))^2$ 微分是 $\sum_{n=1}^N -2((y_n - s_n) - \eta g_t(x_n)) g_t(x_n) = 0$ 。解是 $\eta = \alpha_t$ 。所以 $\sum_{n=1}^N ((y_n - s_n) - \alpha_t g_t(x_n)) g_t(x_n) = 0$ 。用公式 $s_n = s_n + \alpha_t g_t(x_n)$ 把 s_n 更新成最後的 s_n 後，就可以得到 $\sum_{n=1}^N ((y_n - s_n)) g_t(x_n) = 0$

8.

講義上 output layer 的微分沒有 w 的因素，不受影響。但是對於

其他點的微分， $\frac{\partial e_n}{\partial w_{ij}^l} = x_i^{l-1} \delta_j^l$ ，講義中， δ_j^l 的算式有包含 $l+1$ 層的 w ，所以除了 output layer 外，其他 layer 的 gradient 計算結果都是 0。但因為初始所有 w 都是 0，所以對於 output layer 的 x_i^{l-1} 也都是 0。所以 output layer 的 gradient 也是 0。所以所有 w 的 gradient 都是 0。


9.

我設最大深度是 5。要不然跑太慢，後面的題目跑超久。

我的 Eout 是 9.082906857727737


10.

這是我畫的圖



11


這是我畫的圖



可以發現說其實 **G** 比大部分的 **Eout** 還要好。所以選 **G** 是個比較穩定的選擇。

12

這是我畫的圖



其實 **Eout** 晃動幅度非常大，很不穩定。但 **G** 相對穩定在下降。

明顯穩定很多。